빅데이터 분석 시각화

Homework#10

학번 : 2016039029

이름 : 이종영

마감일자 : 23/11/20

Contents

- 1. Data Analysis Processing
- 2. Result

1. Data Analysis Processing

1.1 데이터 분석에 사용될 라이브러리 및 데이터를 호출

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix
from sklearn import metrics
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import MinMaxScaler
from sklearn.naive_bayes import GaussianNB
from sklearn.svm import SVC
```

```
# 2. Import the dataset (same directory)
df = pd.read_csv('melb_data.csv')
```

1.2 데이터 정보 확인 헤더정보, 크기, 데이터 형태

1.3 EDA 수행 종속변수 관계 확인 속성 선정

```
# 4. EDA : target attribute - Type
# h - house,cottage,villa, semi,terrace; u - unit, duplex; t - townhouse;
print(df['Type'].value_counts())
print()
print(df['Type'].value_counts()/np.float64(len(df)))
```

1.4 누락된 필드 체크

'BuildingArea', 'YearBuilt', 'CouncilArea''Car'

4가지 속성에 대해 전처리 필요 이때, 10% 초과인 3개 속성에 대해서는 CDA 진행 그 외 속성에 대해서는 결측값에 대해 대체값을 삽입한다. 각 튜플의 값이 다수건이 확인 되므로 단순대체를 이용한다.


1.5 이상값 확인

이전에 확인한 데이터 중 범주형 데이터에 대한 작업을 진행하는데 방해되는 속성을 제거하며 그 외에는 라벨인코딩으로 동일한 데이터형으로 바꾸어 진행한다

```
# 4. EDA : Not Categorical data
df = df.drop(columns=['Suburb', 'Address', 'Date', 'Lattitude', 'Longtitude', 'Regionname'])

# 4. EDA : Categorical data Labelencoding
encoder = LabelEncoder()
df['Method'] = encoder.fit_transform(np.array(df['Method'].values.reshape(-1,1)))
df['SellerG'] = encoder.fit_transform(np.array(df['SellerG'].values.reshape(-1,1)))
df['Type'] = encoder.fit_transform(np.array(df['Type'].values.reshape(-1,1)))
```

이후 이상값을 다시 확인한다.



다음의 작업에서 3번 컬럼에 대해 조치 되는지 확인하기로 한 다음 다음 절차를 진행한다. 1.6 트레이닝셋을 7의 비율로 세트 및 확인

1.7 K-최근접 이웃법(KNN) 실시 주변 데이터셋 변경하며 정확도 확인

```
# 5. Fit K Neighbours Classifier to the training set
classifier = KNeighborsClassifier(n_neighbors = 5)
classifier.fit(X_train, y_train)
guesses = classifier.predict(X_test)

print(guesses)

> 0.0s

# 6. Check Accuracy Score
print(confusion_matrix(y_test, guesses))
print(metrics.accuracy_score(y_test, guesses))

> 0.0s

# [2605 32 169]
[271 15 58]
[452 25 447]]
0.7528227785959745
```

K=5, 0.752...

K=15, 0.765... K=30, 0.762... 유의미한 차이가 없음 즉 K값을 범위로 두어 시각분석화 할 필요가 있음.

1.7.1 KNN 범위에 대한 시각 분석화


```
# 7. Improving Accuracy: Tuning k parameter
k_range = range(1, 100)

accuracy_scores = []

for k in k_range:
    classifier = KNeighborsClassifier(n_neighbors = k)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(metrics.accuracy_score(y_test, guesses))
print(accuracy_scores)

plt.plot(k_range, accuracy_scores)
plt.xlabel('Value of K for KNN')
plt.ylabel('Testing Accuracy')
plt.show()
```

K = 30까지도 무의미한 차이가 있었으니 값은 100까지 크게 잡아서 식별.



정확도는 위와 같이 확인됨.


1.8 트레이닝 셋, 테스트 셋 비율 변경 (8:2)

```
# 8. Improving Accuracy: Changing split ratio (8:2)
# Tuning k parameter
k_range = range(1, 100)

accuracy_scores = []


for k in k_range:
    classifier = KNeighborsClassifier(n_neighbors = k)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(metrics.accuracy_score(y_test, guesses))
print(accuracy_scores)

plt.plot(k_range, accuracy_scores)
plt.xlabel('Value of K for KNN')
plt.ylabel('Testing Accuracy')
plt.show()
```



정확도가 늘어난 것으로 식별됨 따라서 이후 셋은 8:2 비율로 진행됨.

1.9 정확도 높이기를 위한 속성 관계 시각화



이때, 상관계수에 대해 관계 없는 (0에 수렴)하는 속성값을 제거 함.

다시 모델을 생섬함.


1.10 생성된 모델을 이용 다시한번 정확도를 시각화 함.

```
# 11. Tuning k parameter
k_range = range(1, 100)

accuracy_scores = []

for k in k_range:
    classifier = KNeighborsClassifier(n_neighbors = k)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(metrics.accuracy_score(y_test, guesses))
print(accuracy_scores)

plt.plot(k_range, accuracy_scores)
plt.xlabel('Value of K for KNN')
plt.ylabel('Testing Accuracy')
plt.show()
```



정확도가 0.77 -> 0.79 으로 상승함.

1.12 스케일링 및 속성 분포 확인

√ 0.0s							
	Rooms	Туре	Price	Distance	Bedroom2	Bathroom	Car
count	13580.000000	13580.000000	1.358000e+04	13580.000000	13580.000000	13580.000000	13580.000000
mean	2.937997	0.526362	1.075684e+06	10.137776	2.914728	1.534242	1.610075
std	0.955748	0.832878	6.393107e+05	5.868725	0.965921	0.691712	0.960433
min	1.000000	0.000000	8.500000e+04	0.000000	0.000000	0.000000	0.000000
25%	2.000000	0.000000	6.500000e+05	6.100000	2.000000	1.000000	1.000000
50%	3.000000	0.000000	9.030000e+05	9.200000	3.000000	1.000000	2.000000
75%	3.000000	1.000000	1.330000e+06	13.000000	3.000000	2.000000	2.000000
max	10.000000	2.000000	9.000000e+06	48.100000	20.000000	8.000000	10.000000

값의 범위 차이가 큰 것을 확인 MINMAX 스케일링을 사용하여 다시한번 모델을 생성함.

1.13 정규화 및 트레이닝

```
# 12. Improving Accuracy: Feature Scaling

df = df.copy()

scaler = MinMaxScaler()

features = [['Price', 'Distance']]
  for feature in features:
    df[feature] = scaler.fit_transform(df[feature])

plt.boxplot(df)
plt.xlabel('Attributes')
plt.ylabel('Value')
plt.show()
```

```
# 13. Split data into separate training and test set
   training points - df.drop(columns=['Type'])
   training_labels = df['Type']
   X_train, X_test, y_train, y_test = train_test_split(
      training points,
      training labels,
       test_size=0.2,
      random_state=4)
   print(X_train.shape)
  print(y_train.shape)
   print(X_test.shape)
   print(y_test.shape)
✓ 0.0s
(10864, 6)
(10864,)
(2716, 6)
(2716,)
```


1.14 마지막 정확도 확인

```
# 14. Tuning k parameter
k_range = range(1, 100)

accuracy_scores = []

for k in k_range:
    classifier = KNeighborsClassifier(n_neighbors = k)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(metrics.accuracy_score(y_test, guesses))
print(accuracy_scores)

plt.plot(k_range, accuracy_scores)
plt.xlabel('Value of K for KNN')
plt.ylabel('Testing Accuracy')
plt.show()
```



기존 0.79 -> 0.83 이상으로 정확도를 확보하였고 k값이 적을때의 정확도 또한 증가한것을 식별함.

1.15 NB 적용시 정확도 확인

1.16 SVM 적용시 정확도 확인

1.17 각 정확도 비교 KNN - 0.8306332842415317 NB - 0.7801914580265096 SVM - 0.8085419734904271 NB < SVM < KNN

2. Result

데이터 분석 후 정확도를 상승 시키는 전처리 과정을 진행하였습니다. 오브젝트 데이터를 지우고 기본키를 제거하여 전처리를 진행한 뒤 기준이 될 속성값을 선택하였습니다.

선택된 속성값에 대해 트레이닝셋과 테스트 셋의 비율은 8:2으로 선정하였습니다.

정확도를 높이기 위한 속성간 관계를 시각화 하고 제거한 뒤 정규화를 위한 값의 분포를 확인하고 MINMAXScaler를 진행하여 최종적으로 정확도를 높이는데 성공하였습니다.

3개의 알고리즘의 정확도를 비교한 결과 해당 데이터셋에 대한 타입 속성에 대한 정확도를 높게 얻어내는 알고리즘은 KNN 이었습니다.