빅데이터 분석 시각화

Homework#11

학번 : 2016039029

이름 : 이종영

마감일자 : 23/11/27

Contents

- 1. Data Analysis Processing
- 2. Result

1. Data Analysis Processing

1.1 데이터 분석에 사용될 라이브러리 및 데이터를 호출

```
# 1. Import necessary libraries
 import pandas as pd
 import numpy as np
 import matplotlib.pyplot as plt
 import seaborn as sns
 from sklearn.model_selection import train_test_split
 from sklearn.neighbors import KNeighborsClassifier
 from sklearn.metrics import confusion matrix
 from sklearn import metrics
 from sklearn.impute import SimpleImputer
 from sklearn.preprocessing import LabelEncoder
 from sklearn.preprocessing import MinMaxScaler
 from sklearn.preprocessing import StandardScaler
  ⊕om sklearn.naive_bayes import GaussianNB
 from sklearn.svm import SVC
 from sklearn.tree import DecisionTreeClassifier
 from sklearn.ensemble import RandomForestClassifier
  from sklearn.ensemble import AdaBoostClassifier
  from sklearn.metrics import accuracy_score
# 2. Import the dataset (same directory)
df = pd.read_csv('melb_data.csv')
```

1.2 데이터 정보 확인 헤더정보, 크기, 데이터 형태

```
# 2. Data Visualization
print(ef. had())
print(ef. had())

for col in of. natures:
    print(ef.col)

for col in of. natures:
    print(ef.col).value.counts()/np.float64(lon(ef)))

# 50

    Nuturali Address Homes Type Price Medical Value ()
    Abbotsined 35 Termor St. 2 h 368900.0 5 Slagin
    Abbotsined 35 Termor St. 2 h 368900.0 5 Slagin
    Abbotsined 35 Charles St. 3 h 365900.0 5F Slagin
    Abbotsined 55 Charles St. 3 h 365900.0 5F Slagin
    Abbotsined 55 Charles St. 3 h 365900.0 5F Slagin
    Abbotsined 55 Fark St. 4 h 368900.0 FF Slagin
    Abbotsined 55 Fark St. 4 h 368900.0 VB Relson

    Date Distance Postcode Bethroom Car Landsize BuildingArea \
    X 1/12/2010 2.5 3007.0 . 1.0 10.0 H Not
    1 4/82/2010 2.5 3007.0 . 1.0 10.0 H Not
    1 4/82/2010 2.5 3007.0 . 1.0 3.0 350.0 70.0
    2 4/8 1/901 2.5 3007.0 . 1.0 7.0 310.0 10.0
    4 4/8 1/901 2.5 3007.0 . 1.0 7.0 370.0 157.0

    Yearmilli Countilires Estitude Inglitude
    Rull Varia 57.5003 544.0044 Northern Retropolition
    1 308.0 Varia 17.0003 544.0044 Northern Retropolition
    2 1900.0 Varia 27.0003 544.0044 Northern Retropolition
    308.0 Varia 27.0003 544.0044 Northern Retropolition
    4 308.0 0.000074
1303.0 0.000074
1303.0 0.000074
1303.0 0.000074
1303.0 0.000074
1303.0 0.000074
1303.0 0.000074
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.000076
1303.0 0.0000076
1303.0 0.0000076
1303.0 0.000076
```

1.3 EDA 수행 종속변수 관계 확인 속성 선정

```
# 4. EDA : target attribute - Type
# h - house,cottage,villa, semi,terrace; u - unit, duplex; t - townhouse;
print(df['Type'].value_counts())
print()
print(df['Type'].value_counts()/np.float64(len(df)))
```

1.4 누락된 필드 체크

'BuildingArea','YearBuilt','CouncilArea''Car' 4가지 속성에 대해 전처리 필요 이때, 10% 초과인 3개 속성에 대해서는 CDA 진행 그 외

속성에 대해서는 결측값에 대해 대체값을 삽입한다.

각 튜플의 값이 다수건이 확인 되므로 단순대체를 이용한다.


1.5 이상값 확인

이전에 확인한 데이터 중 범주형 데이터에 대한 작업을 진행하는데 방해되는 속성을 제거하며 그 외에는 라벨인코딩으로 동일한 데이터형으로 바꾸어 진행한다

```
# 4. EDA : Not Categorical data
df = df.drop(columns=['Suburb', 'Address', 'Date', 'Lattitude', 'Longtitude', 'Regionname'])

# 4. EDA : Categorical data Labelencoding
encoder = LabelEncoder()
df['Method'] = encoder.fit_transform(np.array(df['Method'].values.reshape(-1,1)))
df['SellerG'] = encoder.fit_transform(np.array(df['SellerG'].values.reshape(-1,1)))
df['Type'] = encoder.fit_transform(np.array(df['Type'].values.reshape(-1,1)))
```

이후 이상값을 다시 확인한다.



다음의 작업에서 3번 컬럼에 대해 조치 되는지 확인하기로 한 다음 다음 절차를 진행한다. 1.6 트레이닝셋을 8의 비율로 세트 및 확인 시드값은 5

1.7 Gaussian Classifier-Decision Tree 정확도 확인

```
# 6-1. Create a Gaussian Classifier : Decision*Tree classifier = DecisionTreeClassifier(random_state=0) classifier.fit(X_train,y_train) guesses = classifier.predict(X_test)

# 6-2. Check Accuracy Score print("Confusion Matrix: ",confusion_matrix(y_test, guesses)) print("Accuracy: ",metrics.accuracy_score(y_test, guesses))

Confusion Matrix: [[1734 96 65]
[ 80 90 42]
[ 71 71 467]
Accuracy: 0.843519882179676
```

정확도: 0.843519882179676...

1.7.1 Gaussian Classifier-Random Forest 정확도 확인

```
# 6-3 Create a Gaussian Classifier: Random Forest
classifier = RandomForestClassifier(random_state=0, n_estimators=3)
classifier.fit(X_train,y_train)
guesses = classifier.predict(X_test)

# 6-4. Check Accuracy Score
print("Confusion Matrix: ",confusion_matrix(y_test, guesses))
print("Accuracy: ",metrics.accuracy_score(y_test, guesses))

Confusion Matrix: [[1789 50 56]
[ 99 79 34]
[ 84 48 477]]
Accuracy: 0.8634020618556701
```

정확도: 0.8634020618556701...

1.7.2 Gaussian Classifier-Random Forest 트리 수 변경 n=10

```
# 6-5. Create a Gaussian Classifier : Random Forest increasing trees
  classifier = RandomForestClassifier(random_state=0, n_estimators=10)
  classifier.fit(X_train,y_train)
  guesses = classifier.predict(X_test)

# 6-6. Check Accuracy Score
  print("Confusion Matrix: ",confusion_matrix(y_test, guesses))
  print("Accuracy: ",metrics.accuracy_score(y_test, guesses))

Confusion Matrix: [[1805  43  47]
  [ 90  88  34]
  [ 74  44  491]]
  Accuracy: 0.8777614138438881
```

정확도: 0.8777614138438881...

1.7.3 Gaussian Classifier-Random Forest 트리 수 변경 n=100

```
# 6-5. Create a Gaussian Classifier: Random Forest increasing trees classifier = RandomForestClassifier(random_state=0, n_estimators=100) classifier.fit(X_train,y_train) guesses = classifier.predict(X_test)

# 6-6. Check Accuracy Score print("Confusion Matrix: ",confusion_matrix(y_test, guesses)) print("Accuracy: ",metrics.accuracy_score(y_test, guesses))

Confusion Matrix: [[1821 34 40] [ 82 91 39] [ 61 43 505]]
Accuracy: 0.8899116347569955
```

정확도: 0.8899116347569955...

1.7.4 Gaussian Classifier-Random Forest 트리수 변경에 대한 시각화

```
# 7-1. Check Accuracy Score that Gaussian Naive Bayes: Numbers 1 to 100 Trees

n_range = range(1, 100)

accuracy_scores = []

for n in n_range:
    classifier = RandomForestClassifier(random_state=0, n_estimators=n)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(accuracy_score(y_test, guesses))


print(accuracy_scores)

plt.plot(n_range, accuracy_scores)

plt.vlabel('Value of n for Random Forest')

plt.ylabel('Testing Accuracy')

plt.show()
```




1.8 Adaboost vs. Gaussian Naive Bayes

```
# 7-2. Check Accuracy Score that AdaBoost : Numbers 1 to 100 Trees
n_range = range(1, 100)
accuracy_scores = []

for n in n_range:
    classifier = AdaBoostClassifier(random_state=0, n_estimators=n)
    classifier.fit(X_train, y_train)
    guesses = classifier.predict(X_test)
    accuracy_scores.append(accuracy_score(y_test, guesses))
print(accuracy_scores)

plt.plot(n_range, accuracy_scores)
plt.xlabel('Value of n for AdaBoost')
plt.ylabel('Testing Accuracy')
plt.show()
```



2. Result

데이터 분석 후 정확도를 상승 시키는 전처리 과정을 진행하였습니다. 오브젝트 데이터를 지우고 기본키를 제거하여 전처리를 진행한 뒤 기준이 될 속성값을 선택하였습니다.

선택된 속성값에 대해 트레이닝셋과 테스트 셋의 비율은 8:2으로 선정하였습니다.

Gaussian Naive Bayes 알고리즘을 적용해 정확도를 파악하며 이때 의사 정 트리와 랜덤포레스트를 선정하였고, 랜덤포레스트의 트리수를 변화시 키며 정확도를 파악한 뒤 이를 시각화 하였습니다.

마지막으로 Adaboost를 이용해 정확도를 파악하였고 랜덤 포레스트와 비교할 시 램덤포레스트 쪽의 정확도가 더 높게 나오는 것을 확인 할 수 있었습니다.